

INTRODUCTION AU MACHINE LEARNING

MASTER 2 MIAGE SITN

NDIAYE Maïrame

Université Paris Dauphine – PSL

2026–2027

Séance 1 — De « apprendre » à la régression linéaire

COMMENT ALLONS-NOUS TRAVAILLER ?

Cours Construire les idées

Polycopié Comprendre et approfondir

Exercices Raisonner

TP Expérimenter

COMMENT ALLONS-NOUS TRAVAILLER ?

Cours Construire les idées

Polycopié Comprendre et approfondir

Exercices Raisonner

TP Expérimenter

L'objectif n'est pas de mémoriser des algorithmes,
mais de comprendre **pourquoi** ils fonctionnent.


OÙ ALLONS-NOUS?

1


**Apprendre à
partir de données**

Régression linéaire


OÙ ALLONS-NOUS ?




OÙ ALLONS-NOUS ?




OÙ ALLONS-NOUS?



OÙ ALLONS-NOUS ?



OÙ ALLONS-NOUS ?



MODALITÉS D'ÉVALUATION

Note finale

70 %

Examen sur table

20 %

Projet

10 %

Participation

PRÉREQUIS ET OUTILS

Mathématiques

Des bases en :

- ▶ algèbre linéaire
- ▶ probabilités
- ▶ dérivation

Les mathématiques seront introduites lorsque nécessaires.

Python

Être à l'aise avec :

- ▶ NumPy
- ▶ pandas
- ▶ `scikit-learn`

Outils


Nous utiliserons :

- ▶ Google Colab pour les TPs et projet
- ▶ GitHub pour les ressources

Ressources du cours et TP (GitHub)

LES RÈGLES SUFFISENT-ELLES ?


Connaître les règles



Les règles indiquent
ce qui est autorisé.


LES RÈGLES SUFFISENT-ELLES ?

Connaître les règles



Les règles indiquent
ce qui est autorisé.


Choisir le bon coup



Mais elles ne disent pas
quel coup choisir.


LES RÈGLES SUFFISENT-ELLES ?

Connaître les règles



Les règles indiquent
ce **qui** est autorisé.

Choisir le bon coup



Mais elles ne disent pas
quel coup choisir.

Peut-on écrire une règle pour **chaque situation possible** ?

QU'EST-CE QUE LE MACHINE LEARNING ?

Programmation classique




Machine Learning




Apprendre automatiquement à partir des données
sans programmer explicitement toutes les règles.

LE MACHINE LEARNING : POUR QUELS PROBLÈMES ?




LE MACHINE LEARNING : POUR QUELS PROBLÈMES ?



Existe-t-il **un algorithme d'apprentissage** efficace pour tous ces problèmes ?

LE MACHINE LEARNING : POUR QUELS PROBLÈMES ?




Existe-t-il **un algorithme d'apprentissage** efficace pour tous ces problèmes ?

Non.

Le **No-Free-Lunch Theorem** nous dit qu'il n'existe pas d'algorithme universellement meilleur.

TROIS FAÇONS D'APPRENDRE


Apprentissage supervisé



Données + étiquettes

**Apprendre à partir
des étiquettes**


Apprentissage non supervisé



Données sans étiquettes

**Découvrir des
structures cachées**

Apprentissage par renforcement



Interaction dans
un environnement

**Apprendre par
essai, erreur,
récompense**

APPRENTISSAGE SUPERVISÉ

On dispose d'exemples pour lesquels **la réponse est connue**.

Régression



Surface, localisation,
nombre de pièces...

Prix : 420 000 €

Prédire une **valeur numérique**

Classification



Expéditeur, mots utilisés,
liens, contenu...

Spam / Non-spam

Prédire une **catégorie**

D'UN EXEMPLE À UNE OBSERVATION

Pour chaque observation i , on connaît **les informations** et **la réponse associée**.

Informations

Surface : 80 m²

Nombre de pièces : 3

Étage : 4



Réponse

420 000 €

D'UN EXEMPLE À UNE OBSERVATION

Pour chaque observation i , on connaît **les informations** et **la réponse associée**.

Informations

Surface : 80 m²

Nombre de pièces : 3

Étage : 4

$$x^{(i)} \in \mathbb{R}^d$$

Réponse

420 000 €

$$y^{(i)} \in \mathcal{Y}$$

Une observation supervisée est un couple : $(x^{(i)}, y^{(i)})$

DU COUPLE AU JEU DE DONNÉES

On définit $\mathcal{D}$, l'ensemble des observations :

$$\mathcal{D} = \left\{ (x^{(i)}, y^{(i)}) \mid i \leq n, x^{(i)} \in \mathbb{R}^d, y^{(i)} \in \mathcal{Y} \right\}$$

n
nombre
d'observations

d
nombre
d'informations

$\mathcal{Y}$
espace des
étiquettes

DU COUPLE AU JEU DE DONNÉES

On définit $\mathcal{D}$, l'ensemble des observations :

$$\mathcal{D} = \left\{ (x^{(i)}, y^{(i)}) \mid i \leq n, x^{(i)} \in \mathbb{R}^d, y^{(i)} \in \mathcal{Y} \right\}$$

n
nombre
d'observations

d
nombre
d'informations

$\mathcal{Y}$
espace des
étiquettes

Régression

$$\mathcal{Y} \subseteq \mathbb{R}$$

Classification

$\mathcal{Y} = \text{ensemble fini de classes}$

DU JEU DE DONNÉES AUX MATRICES

Matrice des informations

$$X = \begin{pmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{pmatrix}$$

Vecteur des réponses

$$y = \begin{pmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{pmatrix}$$

Une ligne de X = une observation

Une colonne de X = une information

À chaque ligne $x^{(i)}$ de X correspond **une réponse** $y^{(i)}$


QUE CHERCHE-T-ON À APPRENDRE ?

Les données nous donnent des exemples de couples $(x^{(i)}, y^{(i)})$



QUE CHERCHE-T-ON À APPRENDRE ?

Les données nous donnent des exemples de couples $(x^{(i)}, y^{(i)})$




On suppose qu'il existe une relation inconnue f tel que :

$$y^{(i)} = f(x^{(i)}) + \varepsilon^{(i)}$$


COMMENT APPROCHER LA FONCTION INCONNUE ?

Problème : nous ne connaissons pas f .




COMMENT APPROCHER LA FONCTION INCONNUE ?

Problème : nous ne connaissons pas f .



COMMENT APPROCHER LA FONCTION INCONNUE ?


Problème : nous ne connaissons pas f .



On choisit une **famille de fonctions** paramétrée par θ .

COMMENT APPROCHER LA FONCTION INCONNUE ?

Problème : nous ne connaissons pas f .




On choisit une **famille de fonctions** paramétrée par θ .

Apprendre = trouver les paramètres θ à partir des données


PLUSIEURS MODÈLES SONT POSSIBLES

Choisissons une famille simple : $f_{\theta}(x) = \theta_0 + \theta_1 x$




PLUSIEURS MODÈLES SONT POSSIBLES

Choisissons une famille simple : $f_{\theta}(x) = \theta_0 + \theta_1 x$




PLUSIEURS MODÈLES SONT POSSIBLES

Choisissons une famille simple : $f_{\theta}(x) = \theta_0 + \theta_1 x$




PLUSIEURS MODÈLES SONT POSSIBLES

Choisissons une famille simple : $f_{\theta}(x) = \theta_0 + \theta_1 x$



PLUSIEURS MODÈLES SONT POSSIBLES

Choisissons une famille simple : $f_{\theta}(x) = \theta_0 + \theta_1 x$




Lequel choisir?

COMMENT MESURER L'ERREUR D'UNE PRÉDICTION ?

Pour une observation i , le modèle produit une prédiction


$$\hat{y}^{(i)} = f_{\theta} \left(x^{(i)} \right)$$

Valeur réelle



← Quelle différence ? →

Prédiction




COMMENT MESURER L'ERREUR D'UNE PRÉDICTION ?

Pour une observation i , le modèle produit une prédiction


$$\hat{y}^{(i)} = f_{\theta} \left(x^{(i)} \right)$$

Valeur réelle



Quelle différence ?

Prédiction



On introduit la **fonction de perte**

$$\mathcal{L} \left(y^{(i)}, \hat{y}^{(i)} \right)$$

Elle mesure l'erreur commise sur **une observation**.

DE L'ERREUR AU COÛT D'UN MODÈLE

La fonction de perte mesure l'erreur sur **une observation**.

Observation 1

$\mathcal{L}_1$

Observation 2

$\mathcal{L}_2$

...

Observation n

$\mathcal{L}_n$

DE L'ERREUR AU COÛT D'UN MODÈLE

La fonction de perte mesure l'erreur sur **une observation**.

Observation 1

$\mathcal{L}_1$

Observation 2

$\mathcal{L}_2$

...

Observation n

$\mathcal{L}_n$


On agrège ces erreurs pour obtenir une **mesure globale** :

$$\mathcal{C}(f_\theta) = \frac{1}{n} \sum_{i=1}^n \mathcal{L}(y^{(i)}, f_\theta(x^{(i)}))$$

$\mathcal{C}(f_\theta)$ mesure à quel point le modèle se trompe sur les données


APPRENDRE, C'EST OPTIMISER

Chaque choix de paramètres θ définit un modèle f_θ qui as un certain coût...



APPRENDRE, C'EST OPTIMISER

Chaque choix de paramètres θ définit un modèle f_θ qui a un certain coût...




Nous cherchons les paramètres qui rendent ce coût **le plus petit possible**.

$$\theta^* = \arg \min_{\theta} \mathcal{C}(f_\theta)$$

APPRENDRE, C'EST OPTIMISER

Chaque choix de paramètres θ définit un modèle f_θ qui a un certain coût...




Nous cherchons les paramètres qui rendent ce coût **le plus petit possible**.

$$\theta^* = \arg \min_{\theta} \mathcal{C}(f_\theta)$$

Apprendre = trouver les paramètres θ à partir des données qui optimisent la fonction de coût


COMMENT TROUVER LE MINIMUM ?

Nous cherchons $\theta^* = \arg \min_{\theta} \mathcal{C}(\theta)$




COMMENT TROUVER LE MINIMUM ?

Nous cherchons $\theta^* = \arg \min_{\theta} \mathcal{C}(\theta)$




COMMENT TROUVER LE MINIMUM ?

Nous cherchons $\theta^* = \arg \min_{\theta} \mathcal{C}(\theta)$



COMMENT TROUVER LE MINIMUM ?


Nous cherchons $\theta^* = \arg \min_{\theta} \mathcal{C}(\theta)$



Une information locale peut nous aider : **la pente**.


LA PENTE DONNE LA DIRECTION

La dérivée indique comment le coût évolue **localement**.



LA PENTE DONNE LA DIRECTION

La dérivée indique comment le coût évolue **localement**.



Pour faire diminuer le coût, on avance **dans le sens opposé à la dérivée**.

LA DESCENTE DE GRADIENT

On part d'une valeur $\theta^{(0)}$ et on améliore **progressivement** les paramètres.

LA DESCENTE DE GRADIENT

On part d'une valeur $\theta^{(0)}$ et on améliore **progressivement** les paramètres.

$$\theta^{(t+1)} = \theta^{(t)} - \eta \frac{dC}{d\theta} \left(\theta^{(t)} \right)$$

LA DESCENTE DE GRADIENT

On part d'une valeur $\theta^{(0)}$ et on améliore **progressivement** les paramètres.

$$\theta^{(t+1)} = \theta^{(t)} - \eta \frac{dC}{d\theta} \left(\theta^{(t)} \right)$$

$$\theta^{(t)}$$

position actuelle

$$\eta$$

taille du pas

$$\frac{dC}{d\theta}$$

direction locale

LA DESCENTE DE GRADIENT

On part d'une valeur $\theta^{(0)}$ et on améliore **progressivement** les paramètres.

$$\theta^{(t+1)} = \theta^{(t)} - \eta \frac{dC}{d\theta} \left(\theta^{(t)} \right)$$

$$\theta^{(t)}$$

position actuelle

$$\eta$$

taille du pas

$$\frac{dC}{d\theta}$$

direction locale

On répète ces mises à jour jusqu'à **atteindre un minimum**.

QUEL EST LE RÔLE DU LEARNING RATE ?

Dans la descente de gradient :

$$\theta^{(t+1)} = \theta^{(t)} - \eta \frac{dC}{d\theta} (\theta^{(t)})$$

Quel rôle joue le paramètre η dans la mise à jour de θ ?

QUEL EST LE RÔLE DU LEARNING RATE ?

Dans la descente de gradient :

$$\theta^{(t+1)} = \theta^{(t)} - \eta \frac{dC}{d\theta} (\theta^{(t)})$$

Quel rôle joue le paramètre η dans la mise à jour de θ ?



Que va-t-il se passer si η est...

très petit ?



très grand ?

Essayez d'anticiper la trajectoire de θ .

INFLUENCE DU LEARNING RATE




INFLUENCE DU LEARNING RATE





Et si η évoluait pendant l'apprentissage?

Grands pas au début, puis **ajustements plus fins**.





POURQUOI LA CONVEXITÉ EST-ELLE SOUHAITABLE ?

La descente de gradient cherche à atteindre **un minimum** de la fonction de coût.



POURQUOI LA CONVEXITÉ EST-ELLE SOUHAITABLE ?


La descente de gradient cherche à atteindre **un minimum** de la fonction de coût.



Si $\mathcal{C}$ est **convexe**, tout minimum local est également un **minimum global**.

QUEL MODÈLE CHOISIR ?

Trois modèles sont appris à partir des **mêmes données**.




Quel modèle a les
meilleures performances ?

Quel modèle
choisiriez-vous ?

ET SUR DE NOUVELLES DONNÉES ?


Ajoutons maintenant des observations **jamais vues pendant l'apprentissage**.



Quel modèle semble maintenant avoir **le mieux appris** ?

GÉNÉRALISATION ET COMPLEXITÉ DU MODÈLE

La **généralisation** désigne la capacité d'un modèle à être performant sur des **données jamais vues pendant l'apprentissage**.



L'objectif réel d'un modèle d'apprentissage est de **minimiser l'erreur de généralisation**.

ENTRAÎNEMENT, VALIDATION ET TEST

Pour estimer la capacité de **généralisation**, on sépare les données en trois ensembles.

Entraînement

Apprendre
les paramètres
du modèle

Validation


Choisir
le modèle et ses
hyperparamètres

Test

Évaluer
les performances
du modèle final


NOTRE PREMIER MODÈLE : LA RÉGRESSION LINÉAIRE

On souhaite prédire le **prix d'un appartement** à partir de sa **surface**.



NOTRE PREMIER MODÈLE : LA RÉGRESSION LINÉAIRE

On souhaite prédire le **prix d'un appartement** à partir de sa **surface**.




On suppose que la relation peut être approximée par **une droite**.

LE MODÈLE DE RÉGRESSION LINÉAIRE

La régression linéaire repose sur une hypothèse simple :
la variable à prédire peut être approximée par une **combinaison linéaire des variables explicatives**.

$$f_{\theta}(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d = \theta_0 + \sum_{j=1}^d \theta_j x_j$$


Avec une seule variable explicative ($d = 1$) : $\hat{y} = f_{\theta}(x) = \theta_0 + \theta_1 x$



Apprendre le modèle revient à déterminer les paramètres $\theta_0, \theta_1, \dots, \theta_d$.

COMMENT MESURER LES ERREURS ?

Pour chaque observation, le modèle commet une **erreur de prédiction**.



Comment transformer ce résidu en une **perte** ?


Quelle fonction de perte $\mathcal{L}(y, \hat{y})$ pourriez-vous proposer ?

QUELLE FONCTION DE PERTE CHOISIR ?

À partir du résidu $e = y - \hat{y}$, plusieurs fonctions de perte $\mathcal{L}(y, \hat{y})$ sont possibles.

Erreur absolue


$$\mathcal{L}(y, \hat{y}) = |y - \hat{y}| = |e|$$



- ▶ La perte augmente **linéairement** avec $|e|$
- ▶ Non dérivable en $e = 0$

Erreur quadratique

$$\mathcal{L}(y, \hat{y}) = (y - \hat{y})^2 = e^2$$



- ▶ Les grandes erreurs sont **davantage pénalisées**
- ▶ Lisse et dérivable

DE LA PERTE À LA FONCTION DE COÛT

La perte $\mathcal{L}$ mesure l'erreur sur **une observation**.

La fonction de coût $\mathcal{C}$ agrège ces erreurs sur **l'ensemble des données**.

DE LA PERTE À LA FONCTION DE COÛT

La perte $\mathcal{L}$ mesure l'erreur sur **une observation**.

La fonction de coût $\mathcal{C}$ agrège ces erreurs sur **l'ensemble des données**.

Erreur absolue moyenne

$$\mathcal{C}_{\text{MAE}}(\theta) = \frac{1}{n} \sum_{i=1}^n \left| y^{(i)} - \hat{y}^{(i)} \right|$$

DE LA PERTE À LA FONCTION DE COÛT

La perte $\mathcal{L}$ mesure l'erreur sur **une observation**.

La fonction de coût $\mathcal{C}$ agrège ces erreurs sur **l'ensemble des données**.

Erreur absolue moyenne

$$\mathcal{C}_{\text{MAE}}(\theta) = \frac{1}{n} \sum_{i=1}^n |y^{(i)} - \hat{y}^{(i)}|$$

Erreur quadratique moyenne

$$\mathcal{C}_{\text{MSE}}(\theta) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2$$

Choix classique en régression linéaire

DE LA PERTE À LA FONCTION DE COÛT

La perte $\mathcal{L}$ mesure l'erreur sur **une observation**.

La fonction de coût $\mathcal{C}$ agrège ces erreurs sur **l'ensemble des données**.

Erreur absolue moyenne

$$\mathcal{C}_{\text{MAE}}(\theta) = \frac{1}{n} \sum_{i=1}^n |y^{(i)} - \hat{y}^{(i)}|$$

Erreur quadratique moyenne

$$\mathcal{C}_{\text{MSE}}(\theta) = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2$$

Choix classique en régression linéaire

On cherche alors les paramètres qui minimisent le **coût quadratique** :

$$\theta^* = \arg \min_{\theta} \mathcal{C}_{\text{MSE}}(\theta)$$

Minimiser le coût quadratique revient à minimiser la **somme des carrés des résidus** : méthode des **moindres carrés**.

RÉGRESSION LINÉAIRE : ÉCRITURE MATRICIELLE

Pour intégrer l'ordonnée à l'origine θ_0 , on ajoute une **colonne de 1** à la matrice X .

$$X = \begin{pmatrix} 1 & x_1^{(1)} & \cdots & x_d^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(n)} & \cdots & x_d^{(n)} \end{pmatrix} \quad \theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_d \end{pmatrix}$$

RÉGRESSION LINÉAIRE : ÉCRITURE MATRICIELLE

Pour intégrer l'ordonnée à l'origine θ_0 , on ajoute une **colonne de 1** à la matrice X .

$$X = \begin{pmatrix} 1 & x_1^{(1)} & \cdots & x_d^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(n)} & \cdots & x_d^{(n)} \end{pmatrix} \quad \theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_d \end{pmatrix}$$

Les prédictions pour toutes les observations s'écrivent :

$$\hat{y} = X\theta$$

RÉGRESSION LINÉAIRE : ÉCRITURE MATRICIELLE

Pour intégrer l'ordonnée à l'origine θ_0 , on ajoute une **colonne de 1** à la matrice X .

$$X = \begin{pmatrix} 1 & x_1^{(1)} & \cdots & x_d^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(n)} & \cdots & x_d^{(n)} \end{pmatrix} \quad \theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_d \end{pmatrix}$$

Les prédictions pour toutes les observations s'écrivent :

$$\hat{y} = X\theta$$

La fonction de coût quadratique
s'écrit alors sous forme matricielle :

$$C_{\text{MSE}}(\theta) = \frac{1}{n} \|y - X\theta\|_2^2$$

SOLUTION ANALYTIQUE DES MOINDRES CARRÉS

Nous cherchons les paramètres minimisant le coût quadratique :

$$\theta^* = \arg \min_{\theta} \mathcal{C}_{\text{MSE}}(\theta) \quad \mathcal{C}_{\text{MSE}}(\theta) = \frac{1}{n} \|y - X\theta\|_2^2$$

SOLUTION ANALYTIQUE DES MOINDRES CARRÉS

Nous cherchons les paramètres minimisant le coût quadratique :

$$\theta^* = \arg \min_{\theta} \mathcal{C}_{\text{MSE}}(\theta) \quad \mathcal{C}_{\text{MSE}}(\theta) = \frac{1}{n} \|y - X\theta\|_2^2$$

Au minimum, le gradient s'annule :

$$\nabla_{\theta} \mathcal{C}_{\text{MSE}}(\theta^*) = 0$$

SOLUTION ANALYTIQUE DES MOINDRES CARRÉS

Nous cherchons les paramètres minimisant le coût quadratique :

$$\theta^* = \arg \min_{\theta} \mathcal{C}_{\text{MSE}}(\theta) \quad \mathcal{C}_{\text{MSE}}(\theta) = \frac{1}{n} \|y - X\theta\|_2^2$$

Au minimum, le gradient s'annule :

$$\nabla_{\theta} \mathcal{C}_{\text{MSE}}(\theta^*) = 0$$

$$\nabla_{\theta} \mathcal{C}_{\text{MSE}}(\theta) = -\frac{2}{n} X^{\top} (y - X\theta)$$

SOLUTION ANALYTIQUE DES MOINDRES CARRÉS

Nous cherchons les paramètres minimisant le coût quadratique :

$$\theta^* = \arg \min_{\theta} \mathcal{C}_{\text{MSE}}(\theta) \quad \mathcal{C}_{\text{MSE}}(\theta) = \frac{1}{n} \|y - X\theta\|_2^2$$

Au minimum, le gradient s'annule :

$$\nabla_{\theta} \mathcal{C}_{\text{MSE}}(\theta^*) = 0$$

$$\nabla_{\theta} \mathcal{C}_{\text{MSE}}(\theta) = -\frac{2}{n} X^{\top} (y - X\theta)$$

$$X^{\top} (y - X\theta^*) = 0 \quad \implies \quad X^{\top} X\theta^* = X^{\top} y$$

Équations normales

SOLUTION ANALYTIQUE DES MOINDRES CARRÉS

Nous cherchons les paramètres minimisant le coût quadratique :

$$\theta^* = \arg \min_{\theta} \mathcal{C}_{\text{MSE}}(\theta) \quad \mathcal{C}_{\text{MSE}}(\theta) = \frac{1}{n} \|y - X\theta\|_2^2$$

Au minimum, le gradient s'annule :

$$\nabla_{\theta} \mathcal{C}_{\text{MSE}}(\theta^*) = 0$$

$$\nabla_{\theta} \mathcal{C}_{\text{MSE}}(\theta) = -\frac{2}{n} X^{\top} (y - X\theta)$$

$$X^{\top} (y - X\theta^*) = 0 \quad \implies \quad X^{\top} X\theta^* = X^{\top} y$$

Équations normales


Si $X^{\top} X$ est inversible :

$$\theta^* = (X^{\top} X)^{-1} X^{\top} y$$

COMMENT ÉVALUER UNE RÉGRESSION ?

Une fois le modèle appris, on souhaite mesurer sa capacité à **généraliser**.


On l'évalue donc sur des données qui n'ont pas été utilisées pour apprendre ses paramètres.



COMMENT ÉVALUER UNE RÉGRESSION ?

Une fois le modèle appris, on souhaite mesurer sa capacité à **généraliser**.


On l'évalue donc sur des données qui n'ont pas été utilisées pour apprendre ses paramètres.



COMMENT ÉVALUER UNE RÉGRESSION ?

Une fois le modèle appris, on souhaite mesurer sa capacité à **généraliser**.

On l'évalue donc sur des données qui n'ont pas été utilisées pour apprendre ses paramètres.



Comment résumer toutes ces **erreurs de prédiction** par une mesure de performance ?

MESURER L'ERREUR DE PRÉDICTION

Sur un jeu de test de m observations, on compare les valeurs $y^{(i)}$ aux prédictions $\hat{y}^{(i)}$.

MESURER L'ERREUR DE PRÉDICTION

Sur un jeu de test de m observations, on compare les valeurs $y^{(i)}$ aux prédictions $\hat{y}^{(i)}$.

Mean Absolute Error

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y^{(i)} - \hat{y}^{(i)}|$$

Erreur moyenne exprimée dans **la même unité que y** .

MESURER L'ERREUR DE PRÉDICTION

Sur un jeu de test de m observations, on compare les valeurs $y^{(i)}$ aux prédictions $\hat{y}^{(i)}$.

Mean Absolute Error

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y^{(i)} - \hat{y}^{(i)}|$$

Erreur moyenne exprimée dans **la même unité que y** .

Mean Squared Error

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m \left(y^{(i)} - \hat{y}^{(i)} \right)^2$$

Pénalise davantage les **grandes erreurs**.

MESURER L'ERREUR DE PRÉDICTION

Sur un jeu de test de m observations, on compare les valeurs $y^{(i)}$ aux prédictions $\hat{y}^{(i)}$.

Mean Absolute Error

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y^{(i)} - \hat{y}^{(i)}|$$

Erreur moyenne exprimée dans **la même unité que y** .

Mean Squared Error

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m \left(y^{(i)} - \hat{y}^{(i)} \right)^2$$

Pénalise davantage les **grandes erreurs**.


RMSE – Root Mean Squared Error

$$\text{RMSE} = \sqrt{\text{MSE}}$$

Conserve la pénalisation quadratique mais revient dans **l'unité de y** .


LE COEFFICIENT DE DÉTERMINATION R^2

Notre modèle fait-il mieux qu'une **prédiction très simple**?




LE COEFFICIENT DE DÉTERMINATION R^2

Notre modèle fait-il mieux qu'une **prédiction très simple**?




LE COEFFICIENT DE DÉTERMINATION R^2

Notre modèle fait-il mieux qu'une **prédiction très simple**?



LE COEFFICIENT DE DÉTERMINATION R^2


Notre modèle fait-il mieux qu'une **prédiction très simple**?



$$R^2 = 1 - \frac{\sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2}{\sum_{i=1}^m (y^{(i)} - \bar{y})^2}$$

LE COEFFICIENT DE DÉTERMINATION R^2

Notre modèle fait-il mieux qu'une **prédiction très simple** ?



$$R^2 = 1 - \frac{\sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2}{\sum_{i=1}^m (y^{(i)} - \bar{y})^2}$$

Interprétez

$$R^2 = 1 \quad R^2 = 0 \quad R^2 < 0 ?$$

COMMENT INTERPRÉTER R^2 ?

