

INTRODUCTION AU MACHINE LEARNING

MASTER 2 MIAGE SITN


NDIAYE Maïrame

Université Paris Dauphine – PSL


2026–2027

Séance 2 — Généraliser sans surapprendre

D'OÙ PARTONS-NOUS ?



D'OÙ PARTONS-NOUS ?




Jusqu'ici, nous avons fait une **hypothèse forte** :

la relation entre x et y peut être représentée par une droite.

$$f_{\theta}(x) = \theta_0 + \theta_1 x$$

UNE DROITE SUFFIT-ELLE TOUJOURS ?

Considérons le problème de la **consommation de carburant** en fonction de la **vitesse**.



UNE DROITE SUFFIT-ELLE TOUJOURS ?

Considérons le problème de la **consommation de carburant** en fonction de la **vitesse**.



La régression linéaire suffit-elle pour résoudre ce problème ?


APPLICATION DE LA RÉGRESSION LINÉAIRE

Essayons différentes valeurs de $\theta = (\theta_0, \theta_1)$.




APPLICATION DE LA RÉGRESSION LINÉAIRE

Essayons différentes valeurs de $\theta = (\theta_0, \theta_1)$.




APPLICATION DE LA RÉGRESSION LINÉAIRE

Essayons différentes valeurs de $\theta = (\theta_0, \theta_1)$.




APPLICATION DE LA RÉGRESSION LINÉAIRE

Essayons différentes valeurs de $\theta = (\theta_0, \theta_1)$.



APPLICATION DE LA RÉGRESSION LINÉAIRE


Essayons différentes valeurs de $\theta = (\theta_0, \theta_1)$.



Quel est le problème?

APPLICATION DE LA RÉGRESSION LINÉAIRE

Essayons différentes valeurs de $\theta = (\theta_0, \theta_1)$.



Quel est le problème?

Que pourriez-vous proposer comme solution?

UNE FAMILLE DE MODÈLES PLUS FLEXIBLE

Théorème (Théorème d'approximation de Weierstrass).

Soit f une fonction continue définie sur un intervalle fermé $[a, b]$. Alors, il existe une suite de polynômes qui converge uniformément vers $f(x)$ pour $x \in [a, b]$.

Autrement dit, toute fonction continue peut être arbitrairement bien approchée par une suite de polynômes.

UNE FAMILLE DE MODÈLES PLUS FLEXIBLE

Théorème (Théorème d'approximation de Weierstrass).

Soit f une fonction continue définie sur un intervalle fermé $[a, b]$. Alors, il existe une suite de polynômes qui converge uniformément vers $f(x)$ pour $x \in [a, b]$.

Autrement dit, toute fonction continue peut être arbitrairement bien approchée par une suite de polynômes.

Les polynômes constituent donc une famille de fonctions **extrêmement riche**.

Et si nous les utilisons comme modèles ?

DE LA DROITE AU POLYNÔME

Avec une régression linéaire, nous avons $f_{\theta}(x) = \theta_0 + \theta_1 x$.

DE LA DROITE AU POLYNÔME

Avec une régression linéaire, nous avons $f_{\theta}(x) = \theta_0 + \theta_1 x$.

Enrichissons progressivement la famille de modèles :


$$\theta_0 + \theta_1 x \longrightarrow \theta_0 + \theta_1 x + \theta_2 x^2 \longrightarrow \theta_0 + \theta_1 x + \cdots + \theta_p x^p$$

DE LA DROITE AU POLYNÔME

Avec une régression linéaire, nous avons $f_{\theta}(x) = \theta_0 + \theta_1 x$.

Enrichissons progressivement la famille de modèles :

$$\theta_0 + \theta_1 x \longrightarrow \theta_0 + \theta_1 x + \theta_2 x^2 \longrightarrow \theta_0 + \theta_1 x + \cdots + \theta_p x^p$$



EST-CE ENCORE UNE RÉGRESSION LINÉAIRE ?

$$f_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_p x^p$$

EST-CE ENCORE UNE RÉGRESSION LINÉAIRE ?

$$f_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_p x^p$$

Créons simplement de nouvelles variables :

$$x \longrightarrow (x, x^2, x^3, \dots, x^p)$$

EST-CE ENCORE UNE RÉGRESSION LINÉAIRE ?

$$f_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_p x^p$$

Créons simplement de nouvelles variables :

$$x \longrightarrow \left(x, x^2, x^3, \dots, x^p \right)$$

$$f_{\theta}(x) = \underbrace{\theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_p x^p}_{\text{linéaire en } \theta_0, \theta_1, \dots, \theta_p}$$

EST-CE ENCORE UNE RÉGRESSION LINÉAIRE ?

$$f_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_p x^p$$

Créons simplement de nouvelles variables :

$$x \longrightarrow (x, x^2, x^3, \dots, x^p)$$


$$f_{\theta}(x) = \underbrace{\theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_p x^p}_{\text{linéaire en } \theta_0, \theta_1, \dots, \theta_p}$$

La relation est **non linéaire en x** , mais le modèle reste **linéaire en ses paramètres θ** .
C'est donc toujours une **régression linéaire**.


DES RELATIONS DE PLUS EN PLUS COMPLEXES

Avec plusieurs variables explicatives, la même idée permet d'apprendre des relations **beaucoup plus riches**.


Degré 1



Degré 2



Degré 3



Plus le degré augmente, plus la famille de modèles devient **flexible**.

EXERCICE — RÉGRESSION POLYNOMIALE

On entraîne plusieurs régressions polynomiales pour prédire le **prix d'un logement** à partir de sa **surface**.

Prix exprimés en milliers d'euros.

Surface (m^2)	50	80	110
Prix réel	200	300	400

Prédictions sur le jeu de validation

Degré p	$\hat{y}_1$	$\hat{y}_2$	$\hat{y}_3$	RMSE validation
1	150	300	450	
2	165	300	435	
3	175	300	425	
5	180	300	420	
10	140	300	460	

Calculez le RMSE de validation de chaque modèle.

EXERCICE — QUEL MODÈLE CHOISIR ?

On a obtenu les performances suivantes sur le train :

Degré p	RMSE train
1	42.1
2	28.4
3	21.7
5	15.2
10	4.8

1. Quel degré choisiriez-vous ?
2. Quels modèles semblent trop simples ? Trop complexes ?
3. Le degré 10 obtient la meilleure performance sur le jeu d'entraînement. Pourquoi ne pas le choisir ?

EXERCICE — QUEL MODÈLE CHOISIR ?

On a obtenu les performances suivantes sur le train :

Degré p	RMSE train
1	42.1
2	28.4
3	21.7
5	15.2
10	4.8

1. Quel degré choisiriez-vous ?
2. Quels modèles semblent trop simples ? Trop complexes ?
3. Le degré 10 obtient la meilleure performance sur le jeu d'entraînement. Pourquoi ne pas le choisir ?

Que se passe-t-il lorsque la complexité du modèle augmente ?

PLUS COMPLEXE SIGNIFIE-T-IL MEILLEUR ?

Dans l'exercice, lorsque le degré p augmente...

PLUS COMPLEXE SIGNIFIE-T-IL MEILLEUR ?

Dans l'exercice, lorsque le degré p augmente...

Erreur d'entraînement
elle continue de **diminuer**

PLUS COMPLEXE SIGNIFIE-T-IL MEILLEUR ?

Dans l'exercice, lorsque le degré p augmente...

Erreur d'entraînement
elle continue de **diminuer**

Erreur de validation
elle diminue...
puis **augmente**

PLUS COMPLEXE SIGNIFIE-T-IL MEILLEUR ?

Dans l'exercice, lorsque le degré p augmente...

Erreur d'entraînement
elle continue de **diminuer**

Erreur de validation
elle diminue...
puis **augmente**

Un modèle peut donc être **excellent sur les données d'entraînement**
et mauvais sur de nouvelles données.

PLUS COMPLEXE SIGNIFIE-T-IL MEILLEUR ?

Dans l'exercice, lorsque le degré p augmente...


Erreur d'entraînement
elle continue de **diminuer**

Erreur de validation
elle diminue...
puis **augmente**


Un modèle peut donc être **excellent sur les données d'entraînement**
et mauvais sur de nouvelles données.

C'est un problème de **généralisation**.

DE LA COMPLEXITÉ AU SURAPPRENTISSAGE




DE LA COMPLEXITÉ AU SURAPPRENTISSAGE



Le bon modèle n'est donc ni le plus simple, ni nécessairement le plus complexe.

DE LA COMPLEXITÉ AU SURAPPRENTISSAGE




Le bon modèle n'est donc ni le plus simple, ni nécessairement le plus complexe.

Comment trouver le bon niveau de complexité?

BIAIS ET VARIANCE : UNE INTUITION

Un archer réalise quatre séances de tir dans les mêmes conditions.


Voici les résultats obtenus lors de chaque séance.



BIAIS ET VARIANCE : UNE INTUITION

Un archer réalise quatre séances de tir dans les mêmes conditions.

Voici les résultats obtenus lors de chaque séance.




Biais : où se situent les résultats en moyenne ?

Variance : à quel point sont-ils dispersés ?

BIAIS ET VARIANCE : UNE INTUITION

Un archer réalise quatre séances de tir dans les mêmes conditions.

Voici les résultats obtenus lors de chaque séance.



Biais : où se situent les résultats en moyenne ?


Variance : à quel point sont-ils dispersés ?

Pour chaque séance, déterminez si le **biais** et la **variance** sont **faibles** ou **élevés**.


BIAIS ET VARIANCE : UNE INTUITION

Un archer réalise quatre séances de tir dans les mêmes conditions.


Voici les résultats obtenus lors de chaque séance.




Biais faible
Variance faible



Biais faible
Variance élevée



Biais élevé
Variance faible



Biais élevé
Variance élevée


Biais : où se situent les résultats en moyenne ?

Variance : à quel point sont-ils dispersés ?

Pour chaque séance, déterminez si le **biais** et la **variance** sont **faibles** ou **élevés**.


DU TIR AU MACHINE LEARNING

Transposons maintenant cette expérience au Machine Learning.




DU TIR AU MACHINE LEARNING

Transposons maintenant cette expérience au Machine Learning.



DU TIR AU MACHINE LEARNING

Transposons maintenant cette expérience au Machine Learning.



Biais élevé $\Rightarrow$ les modèles appris sont en moyenne **loin de la vraie relation f** .

Variance élevée $\Rightarrow$ le modèle appris **change fortement** lorsque les données d'entraînement changent.

D'OÙ VIENT L'ERREUR DE GÉNÉRALISATION ?

Sur de nouvelles données, l'erreur d'un modèle peut avoir plusieurs origines.

D'OÙ VIENT L'ERREUR DE GÉNÉRALISATION ?

Sur de nouvelles données, l'erreur d'un modèle peut avoir plusieurs origines.

1. Le biais

Le modèle est trop contraint pour représenter correctement la relation réelle.

D'OÙ VIENT L'ERREUR DE GÉNÉRALISATION ?

Sur de nouvelles données, l'erreur d'un modèle peut avoir plusieurs origines.

1. Le biais

Le modèle est trop contraint pour représenter correctement la relation réelle.

2. La variance

Le modèle est trop sensible aux données utilisées pour l'entraîner.

D'OÙ VIENT L'ERREUR DE GÉNÉRALISATION ?

Sur de nouvelles données, l'erreur d'un modèle peut avoir plusieurs origines.

1. Le biais

Le modèle est trop contraint pour représenter correctement la relation réelle.

2. La variance

Le modèle est trop sensible aux données utilisées pour l'entraîner.

3. L'erreur irréductible

Une partie de la variabilité des observations ne peut pas être expliquée par le modèle.

DÉCOMPOSITION BIAIS–VARIANCE

Pour l'erreur quadratique, l'erreur de généralisation peut se décomposer en ces trois termes.

DÉCOMPOSITION BIAIS–VARIANCE

Pour l'erreur quadratique, l'erreur de généralisation peut se décomposer en ces trois termes.

$$\underbrace{\mathbb{E}\left[(Y - f_{\theta^*}(X))^2\right]}_{\text{MSE}} = \underbrace{(f(X) - \mathbb{E}[f_{\theta^*}(X)])^2}_{\substack{\text{Erreur d'approximation} \\ \text{Biais}^2}} + \underbrace{\mathbb{E}\left[(f_{\theta^*}(X) - \mathbb{E}[f_{\theta^*}(X)])^2\right]}_{\substack{\text{Erreur d'estimation} \\ \text{Variance}}} + \underbrace{\sigma^2}_{\substack{\text{Erreur} \\ \text{irréductible}}}$$


DÉCOMPOSITION BIAIS–VARIANCE

Pour l'erreur quadratique, l'erreur de généralisation peut se décomposer en ces trois termes.


$$\underbrace{\mathbb{E}\left[(Y - f_{\theta^*}(X))^2\right]}_{\text{MSE}} = \underbrace{(f(X) - \mathbb{E}[f_{\theta^*}(X)])^2}_{\substack{\text{Erreur d'approximation} \\ \text{Biais}^2}} + \underbrace{\mathbb{E}\left[(f_{\theta^*}(X) - \mathbb{E}[f_{\theta^*}(X)])^2\right]}_{\substack{\text{Erreur d'estimation} \\ \text{Variance}}} + \underbrace{\sigma^2}_{\substack{\text{Erreur} \\ \text{irréductible}}}$$

Que deviennent ces trois termes lorsque la complexité du modèle augmente ?


LE COMPROMIS BIAIS–VARIANCE




LE COMPROMIS BIAIS–VARIANCE




LE COMPROMIS BIAIS–VARIANCE




LE COMPROMIS BIAIS–VARIANCE




LE COMPROMIS BIAIS-VARIANCE



LE COMPROMIS BIAIS-VARIANCE



LE COMPROMIS BIAIS-VARIANCE



Le meilleur niveau de complexité cherche à **équilibrer biais et variance**.

COMMENT CONTRÔLER LA COMPLEXITÉ ?

Nous voulons un modèle suffisamment flexible pour apprendre...
...sans qu'il s'adapte trop aux données d'entraînement.

COMMENT CONTRÔLER LA COMPLEXITÉ ?

Nous voulons un modèle suffisamment flexible pour apprendre...
...sans qu'il s'adapte trop aux données d'entraînement.

$$\underbrace{\min_{\theta} \mathcal{C}(\theta)}_{\text{bien ajuster les données}}$$

COMMENT CONTRÔLER LA COMPLEXITÉ ?

Nous voulons un modèle suffisamment flexible pour apprendre...
...sans qu'il s'adapte trop aux données d'entraînement.

$$\underbrace{\min_{\theta} \mathcal{C}(\theta)}_{\text{bien ajuster les données}}$$

Mais minimiser uniquement l'erreur d'entraînement peut conduire à un modèle **trop complexe**.

COMMENT CONTRÔLER LA COMPLEXITÉ ?

Nous voulons un modèle suffisamment flexible pour apprendre...
...sans qu'il s'adapte trop aux données d'entraînement.

$$\underbrace{\min_{\theta} \mathcal{C}(\theta)}_{\text{bien ajuster les données}}$$

Mais minimiser uniquement l'erreur d'entraînement peut conduire à un modèle **trop complexe**.

Et si nous faisons payer au modèle sa complexité ?

COMMENT CONTRÔLER LA COMPLEXITÉ ?

Nous voulons un modèle suffisamment flexible pour apprendre...
...sans qu'il s'adapte trop aux données d'entraînement.

$$\underbrace{\min_{\theta} \mathcal{C}(\theta)}_{\text{bien ajuster les données}}$$

Mais minimiser uniquement l'erreur d'entraînement peut conduire à un modèle **trop complexe**.

Et si nous faisons payer au modèle sa complexité ?

$$\min_{\theta} \underbrace{\mathcal{C}(\theta)}_{\text{ajustement}} + \lambda \underbrace{\Omega(\theta)}_{\text{complexité}}$$

COMMENT CONTRÔLER LA COMPLEXITÉ ?

Nous voulons un modèle suffisamment flexible pour apprendre...
...sans qu'il s'adapte trop aux données d'entraînement.

$$\underbrace{\min_{\theta} \mathcal{C}(\theta)}_{\text{bien ajuster les données}}$$

Mais minimiser uniquement l'erreur d'entraînement peut conduire à un modèle **trop complexe**.

Et si nous faisons payer au modèle sa complexité ?

$$\boxed{\min_{\theta} \underbrace{\mathcal{C}(\theta)}_{\text{ajustement}} + \lambda \underbrace{\Omega(\theta)}_{\text{complexité}}}$$

C'est le principe de la **régularisation**.

RIDGE : PÉNALISER LES GRANDS COEFFICIENTS

Une première idée : considérer qu'un modèle est plus complexe lorsque ses coefficients deviennent **grands**.

RIDGE : PÉNALISER LES GRANDS COEFFICIENTS

Une première idée : considérer qu'un modèle est plus complexe lorsque ses coefficients deviennent **grands**.

$$\Omega(\theta) = \|\theta\|_2^2 = \sum_{j=1}^d \theta_j^2$$

RIDGE : PÉNALISER LES GRANDS COEFFICIENTS

Une première idée : considérer qu'un modèle est plus complexe lorsque ses coefficients deviennent **grands**.

$$\Omega(\theta) = \|\theta\|_2^2 = \sum_{j=1}^d \theta_j^2$$

On obtient la **régression Ridge** :

$$\mathcal{C}_{\text{Ridge}}(\theta) = \underbrace{\frac{1}{n} \sum_{i=1}^n \left(y^{(i)} - f_{\theta}(x^{(i)}) \right)^2}_{\text{erreur d'ajustement}} + \lambda \underbrace{\sum_{j=1}^d \theta_j^2}_{\text{pénalité}}$$

RIDGE : PÉNALISER LES GRANDS COEFFICIENTS

Une première idée : considérer qu'un modèle est plus complexe lorsque ses coefficients deviennent **grands**.

$$\Omega(\theta) = \|\theta\|_2^2 = \sum_{j=1}^d \theta_j^2$$

On obtient la **régression Ridge** :

$$\mathcal{C}_{\text{Ridge}}(\theta) = \underbrace{\frac{1}{n} \sum_{i=1}^n \left(y^{(i)} - f_{\theta}(x^{(i)}) \right)^2}_{\text{erreur d'ajustement}} + \lambda \underbrace{\sum_{j=1}^d \theta_j^2}_{\text{pénalité}}$$

Ridge encourage donc des coefficients **plus petits**.

EXERCICE — RÉGULARISATION RIDGE

Deux modèles donnent les coefficients suivants :

$$\theta_A = (4, 3) \qquad \theta_B = (2, 1)$$

Leurs erreurs d'ajustement sur les données d'entraînement sont :


$$\mathcal{C}(\theta_A) = 10 \qquad \mathcal{C}(\theta_B) = 18$$

On utilise le critère Ridge :

$$\mathcal{C}_{\text{Ridge}}(\theta) = \mathcal{C}(\theta) + \lambda \|\theta\|_2^2$$


1. Quel modèle choisit-on pour $\lambda = 0$?
2. Quel modèle choisit-on pour $\lambda = 1$?
3. Pourquoi accepter un modèle qui ajuste moins bien les données d'entraînement ?
4. Que risque-t-il de se passer lorsque $\lambda \rightarrow +\infty$?

RIDGE : OÙ SE TROUVE LA SOLUTION ?




1. Où voudrions-nous aller
si aucune contrainte n'existait ?

RIDGE : OÙ SE TROUVE LA SOLUTION ?




Au **centre des courbes de niveau** :
c'est là que l'erreur est minimale.

RIDGE : OÙ SE TROUVE LA SOLUTION ?




2. Quelles valeurs de θ sont maintenant autorisées?

RIDGE : OÙ SE TROUVE LA SOLUTION ?




Les solutions autorisées sont celles **à l'intérieur du disque**.
Le minimum sans contrainte n'est donc plus accessible.

RIDGE : OÙ SE TROUVE LA SOLUTION ?




3. Parmi toutes les solutions autorisées, laquelle donne la plus petite erreur ?

RIDGE : OÙ SE TROUVE LA SOLUTION ?




La première courbe de niveau qui atteint la région autorisée donne la **solution optimale**.

RIDGE : OÙ SE TROUVE LA SOLUTION ?



4. Que remarquez-vous sur les coefficients θ_1 et θ_2 de cette solution ?

RIDGE : OÙ SE TROUVE LA SOLUTION ?



$\theta_1 \neq 0$ et $\theta_2 \neq 0$
Ridge **réduit la taille des coefficients**,
mais ne les annule généralement pas.

RIDGE : SOLUTION ANALYTIQUE

Pour la régression linéaire classique :

$$\mathcal{C}(\theta) = \|y - X\theta\|_2^2 \quad \implies \quad \theta^* = (X^\top X)^{-1} X^\top y$$

Cette expression nécessite que $X^\top X$ soit inversible.

RIDGE : SOLUTION ANALYTIQUE

Pour la régression linéaire classique :

$$\mathcal{C}(\theta) = \|y - X\theta\|_2^2 \quad \implies \quad \theta^* = (X^\top X)^{-1} X^\top y$$

Cette expression nécessite que $X^\top X$ soit inversible.

Avec Ridge, nous minimisons :

$$\mathcal{C}_{\text{Ridge}}(\theta) = \|y - X\theta\|_2^2 + \lambda \|\theta\|_2^2$$

RIDGE : SOLUTION ANALYTIQUE

Pour la régression linéaire classique :

$$\mathcal{C}(\theta) = \|y - X\theta\|_2^2 \quad \implies \quad \theta^* = (X^\top X)^{-1} X^\top y$$

Cette expression nécessite que $X^\top X$ soit inversible.

Avec Ridge, nous minimisons :

$$\mathcal{C}_{\text{Ridge}}(\theta) = \|y - X\theta\|_2^2 + \lambda \|\theta\|_2^2$$

La condition $\nabla_{\theta} \mathcal{C}_{\text{Ridge}}(\theta) = 0$ conduit à :

$$\theta_{\text{Ridge}}^* = \left(X^\top X + \lambda I \right)^{-1} X^\top y$$

RIDGE : SOLUTION ANALYTIQUE

Pour la régression linéaire classique :

$$\mathcal{C}(\theta) = \|y - X\theta\|_2^2 \quad \implies \quad \theta^* = (X^\top X)^{-1} X^\top y$$

Cette expression nécessite que $X^\top X$ soit inversible.

Avec Ridge, nous minimisons :

$$\mathcal{C}_{\text{Ridge}}(\theta) = \|y - X\theta\|_2^2 + \lambda \|\theta\|_2^2$$

La condition $\nabla_{\theta} \mathcal{C}_{\text{Ridge}}(\theta) = 0$ conduit à :

$$\theta_{\text{Ridge}}^* = \left(X^\top X + \lambda I \right)^{-1} X^\top y$$

Pour $\lambda > 0$, $X^\top X + \lambda I$ est **toujours inversible**.

La solution Ridge existe donc de manière unique, **sans condition de rang** sur X .

EXERCICE — CALCULER UNE SOLUTION RIDGE

On considère les données d'entraînement suivantes :

$$X = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}, \quad y = \begin{pmatrix} 2 \\ 4 \\ 4 \end{pmatrix}, \quad \lambda = 1.$$

On rappelle que la solution Ridge vérifie :

$$\theta_{\text{Ridge}}^* = (X^\top X + \lambda I)^{-1} X^\top y.$$

1. Calculez $X^\top X$.
2. Calculez $X^\top X + \lambda I$ et $X^\top y$.
3. Plutôt que de calculer $(X^\top X + \lambda I)^{-1}$, montrez que θ_{Ridge}^* peut être obtenu en résolvant un **système linéaire**.
4. Écrivez ce système puis déterminez θ_{Ridge}^* .

LASSO : CHANGER LA PÉNALISATION

Ridge utilise la pénalisation L_2 :

$$\Omega_{\text{Ridge}}(\theta) = \sum_{j=1}^d \theta_j^2$$

LASSO : CHANGER LA PÉNALISATION

Ridge utilise la pénalisation L_2 :

$$\Omega_{\text{Ridge}}(\theta) = \sum_{j=1}^d \theta_j^2$$

Lasso remplace les carrés par les **valeurs absolues** :

$$\Omega_{\text{Lasso}}(\theta) = \|\theta\|_1 = \sum_{j=1}^d |\theta_j|$$

$$\mathcal{C}_{\text{Lasso}}(\theta) = \mathcal{C}(\theta) + \lambda \sum_{j=1}^d |\theta_j|$$

LASSO : CHANGER LA PÉNALISATION

Ridge utilise la pénalisation L_2 :

$$\Omega_{\text{Ridge}}(\theta) = \sum_{j=1}^d \theta_j^2$$


Lasso remplace les carrés par les **valeurs absolues** :

$$\Omega_{\text{Lasso}}(\theta) = \|\theta\|_1 = \sum_{j=1}^d |\theta_j|$$

$$\mathcal{C}_{\text{Lasso}}(\theta) = \mathcal{C}(\theta) + \lambda \sum_{j=1}^d |\theta_j|$$

Cette petite modification change profondément la **solution**. Mais pourquoi?


RIDGE VS LASSO : QUE CHANGE LA CONTRAINTE ?




Nous allons résoudre graphiquement les deux problèmes.

RIDGE VS LASSO : QUE CHANGE LA CONTRAINTE ?

Ridge : contrainte L_2




Lasso : contrainte L_1




Quelle forme prend la contrainte L_1 de Lasso ?

RIDGE VS LASSO : QUE CHANGE LA CONTRAINTE ?

Ridge : contrainte L_2




Lasso : contrainte L_1




RIDGE VS LASSO : QUE CHANGE LA CONTRAINTE ?

Ridge : contrainte L_2




Lasso : contrainte L_1




Dans chaque cas, où se trouve la solution optimale ?

RIDGE VS LASSO : QUE CHANGE LA CONTRAINTE ?

Ridge : contrainte L_2




Lasso : contrainte L_1




Que remarquez-vous dans le cas de Lasso ?

RIDGE VS LASSO : QUE CHANGE LA CONTRAINTE ?

Ridge : contrainte L_2



Lasso : contrainte L_1



Les **coins** de la contrainte L_1 sont situés sur les axes.
Lasso peut donc conduire à des coefficients **exactement nuls**.

LASSO : RÉGULARISER ET SÉLECTIONNER

Lasso minimise :

$$\mathcal{C}_{\text{Lasso}}(\theta) = \mathcal{C}(\theta) + \lambda \sum_{j=1}^d |\theta_j|$$

La pénalisation L_1 peut conduire à :

$$\theta_j^* = 0$$

LASSO : RÉGULARISER ET SÉLECTIONNER

Lasso minimise :

$$\mathcal{C}_{\text{Lasso}}(\theta) = \mathcal{C}(\theta) + \lambda \sum_{j=1}^d |\theta_j|$$

La pénalisation L_1 peut conduire à :

$$\theta_j^* = 0$$

Lasso produit ainsi des modèles **parcimonieux** : seules certaines variables restent actives.

ELASTICNET : COMBINER RIDGE ET LASSO

Peut-on combiner les deux types de régularisation ?

ELASTICNET : COMBINER RIDGE ET LASSO

Peut-on combiner les deux types de régularisation ?

$$\mathcal{C}_{\text{ElasticNet}}(\theta) = \mathcal{C}(\theta) + \lambda \left[\alpha \|\theta\|_1 + (1 - \alpha) \|\theta\|_2^2 \right]$$

$$\alpha \in [0, 1]$$

ELASTICNET : COMBINER RIDGE ET LASSO

Peut-on combiner les deux types de régularisation ?

$$\mathcal{C}_{\text{ElasticNet}}(\theta) = \mathcal{C}(\theta) + \lambda \left[\alpha \|\theta\|_1 + (1 - \alpha) \|\theta\|_2^2 \right]$$

$$\alpha \in [0, 1]$$

Que se passe-t-il
lorsque $\alpha = 0$?

Que se passe-t-il
lorsque $\alpha = 1$?

ELASTICNET : COMBINER RIDGE ET LASSO

Peut-on combiner les deux types de régularisation ?

$$\mathcal{C}_{\text{ElasticNet}}(\theta) = \mathcal{C}(\theta) + \lambda \left[\alpha \|\theta\|_1 + (1 - \alpha) \|\theta\|_2^2 \right]$$

$$\alpha \in [0, 1]$$

Que se passe-t-il
lorsque $\alpha = 0$?

$$\begin{aligned} \alpha &= 0 \\ \mathcal{C}(\theta) + \lambda \|\theta\|_2^2 \\ \Rightarrow \text{Ridge} \end{aligned}$$

Que se passe-t-il
lorsque $\alpha = 1$?

$$\begin{aligned} \alpha &= 1 \\ \mathcal{C}(\theta) + \lambda \|\theta\|_1 \\ \Rightarrow \text{Lasso} \end{aligned}$$

ELASTICNET : COMBINER RIDGE ET LASSO

Peut-on combiner les deux types de régularisation ?

$$\mathcal{C}_{\text{ElasticNet}}(\theta) = \mathcal{C}(\theta) + \lambda \left[\alpha \|\theta\|_1 + (1 - \alpha) \|\theta\|_2^2 \right]$$

$$\alpha \in [0, 1]$$

Que se passe-t-il
lorsque $\alpha = 0$?

$$\begin{aligned} \alpha &= 0 \\ \mathcal{C}(\theta) + \lambda \|\theta\|_2^2 \\ \Rightarrow \text{Ridge} \end{aligned}$$

Que se passe-t-il
lorsque $\alpha = 1$?

$$\begin{aligned} \alpha &= 1 \\ \mathcal{C}(\theta) + \lambda \|\theta\|_1 \\ \Rightarrow \text{Lasso} \end{aligned}$$

Pour $0 < \alpha < 1$, ElasticNet réalise un **compromis entre les pénalisations L_1 et L_2 .**

ELASTICNET : COMBINER RIDGE ET LASSO

Peut-on combiner les deux types de régularisation ?

$$\mathcal{C}_{\text{ElasticNet}}(\theta) = \mathcal{C}(\theta) + \lambda \left[\alpha \|\theta\|_1 + (1 - \alpha) \|\theta\|_2^2 \right]$$

$$\alpha \in [0, 1]$$

Que se passe-t-il
lorsque $\alpha = 0$?

$$\begin{aligned} \alpha &= 0 \\ \mathcal{C}(\theta) + \lambda \|\theta\|_2^2 \\ \Rightarrow \text{Ridge} \end{aligned}$$

Que se passe-t-il
lorsque $\alpha = 1$?

$$\begin{aligned} \alpha &= 1 \\ \mathcal{C}(\theta) + \lambda \|\theta\|_1 \\ \Rightarrow \text{Lasso} \end{aligned}$$

Pour $0 < \alpha < 1$, ElasticNet réalise un **compromis entre les pénalisations L_1 et L_2 .**

Mais donc... **comment choisir λ et α ?**

COMMENT CHOISIR LE BON MODÈLE ?

Au cours de cette séance, plusieurs choix sont apparus...

COMMENT CHOISIR LE BON MODÈLE ?

Au cours de cette séance, plusieurs choix sont apparus...

Régression
polynomiale
degré p

COMMENT CHOISIR LE BON MODÈLE ?

Au cours de cette séance, plusieurs choix sont apparus...

Régression
polynomiale
degré p

Ridge / Lasso
 λ

COMMENT CHOISIR LE BON MODÈLE ?

Au cours de cette séance, plusieurs choix sont apparus...

**Régression
polynomiale**
degré p

Ridge / Lasso
 λ

ElasticNet
 λ, α

COMMENT CHOISIR LE BON MODÈLE ?

Au cours de cette séance, plusieurs choix sont apparus...

**Régression
polynomiale**
degré p

Ridge / Lasso
 λ

ElasticNet
 λ, α

Ces quantités ne sont pas apprises directement comme les coefficients θ .

COMMENT CHOISIR LE BON MODÈLE ?

Au cours de cette séance, plusieurs choix sont apparus...

Régression
polynomiale
degré p

Ridge / Lasso
 λ

ElasticNet
 λ, α

Ces quantités ne sont pas apprises directement comme les coefficients θ .

Ce sont des **hyperparamètres** : ils contrôlent
la manière dont le modèle est appris.

COMMENT CHOISIR LE BON MODÈLE ?

Au cours de cette séance, plusieurs choix sont apparus...

Régression
polynomiale
degré p

Ridge / Lasso
 λ

ElasticNet
 λ, α

Ces quantités ne sont pas apprises directement comme les coefficients θ .

Ce sont des **hyperparamètres** : ils contrôlent
la manière dont le modèle est appris.

Comment choisir leurs valeurs ?

UN SEUL JEU DE VALIDATION SUFFIT-IL ?

Nous séparons les données en entraînement et validation.



Mais si nous avons fait un **autre découpage**...

Aurions-nous forcément choisi le **même modèle**?

UN SEUL JEU DE VALIDATION SUFFIT-IL ?

Nous séparons les données en entraînement et validation.



Mais si nous avons fait un **autre découpage**...

Aurions-nous forcément choisi le **même modèle**?

Le choix peut dépendre du hasard du découpage.

VALIDATION CROISÉE : K -FOLD

Découpons les données d'entraînement en $K = 5$ groupes.

Fold 1

Fold 2

Fold 3

Fold 4

Fold 5

VALIDATION CROISÉE : K -FOLD

Découpons les données d'entraînement en $K = 5$ groupes.



VALIDATION CROISÉE : K -FOLD

Découpons les données d'entraînement en $K = 5$ groupes.

	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Itération 1	V				
Itération 2		V			

VALIDATION CROISÉE : K -FOLD

Découpons les données d'entraînement en $K = 5$ groupes.

	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Itération 1	V				
Itération 2		V			
Itération 3			V		
Itération 4				V	
Itération 5					V

À chaque itération : **1 fold pour valider**, les $K - 1$ autres pour **entraîner**.

VALIDATION CROISÉE : QUEL SCORE RETENIR ?

Chaque fold nous donne une estimation différente de l'erreur de généralisation.

Fold 1

E_1

Fold 2

E_2

Fold 3

E_3

Fold 4


E_4

Fold 5

E_5

VALIDATION CROISÉE : QUEL SCORE RETENIR ?

Chaque fold nous donne une estimation différente de l'erreur de généralisation.




On les agrège en calculant leur moyenne :

$$\text{Erreur}_{CV} = \frac{1}{K} \sum_{k=1}^K E_k$$

VALIDATION CROISÉE : QUEL SCORE RETENIR ?

Chaque fold nous donne une estimation différente de l'erreur de généralisation.



On les agrège en calculant leur moyenne :

$$\text{Erreur}_{CV} = \frac{1}{K} \sum_{k=1}^K E_k$$

Nous ne dépendons plus d'un **unique découpage** entraînement / validation. Nous avons une estimation plus **robuste** des performances de notre modèle.

EXERCICE — CHOISIR λ PAR VALIDATION CROISÉE

On souhaite entraîner une régression Ridge.

Quatre valeurs de λ sont comparées par **validation croisée à 5 folds**.

λ	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	RMSE CV
0.01	25	29	27	31	28	
0.1	23	24	25	26	22	
1	21	22	23	22	22	
10	28	27	29	30	26	

1. Calculez la RMSE moyenne pour chaque valeur de λ .
2. Quelle valeur de λ choisiriez-vous?
3. Que suggèrent les résultats pour $\lambda = 0.01$ et $\lambda = 10$?

EXERCICE — ET MAINTENANT ?

La validation croisée nous conduit à choisir :

$$\lambda^* = 1$$

Que faisons-nous maintenant ?

- A. On annonce directement $\text{RMSE} = 22$ comme performance finale.
- B. On teste plusieurs valeurs de λ sur le jeu de test et on garde la meilleure.
- C. On réentraîne avec $\lambda = 1$, puis on utilise le jeu de test pour annoncer les résultats.

LE RASOIR D'OCCAM

*« Les entités ne doivent pas être multipliées
sans nécessité. »*

LE RASOIR D'OCCAM

*« Les entités ne doivent pas être multipliées
sans nécessité. »*

En Machine Learning :

À performances comparables
sur des données nouvelles,
préférer le modèle le plus simple.

LE RASOIR D'OCCAM

*« Les entités ne doivent pas être multipliées
sans nécessité. »*

En Machine Learning :

À performances comparables
sur des données nouvelles,
préférer le modèle le plus simple.

La complexité doit être **justifiée par les données**, pas recherchée pour elle-même.